

Tài liệu Mô tả Dữ liệu

Hệ thống Truy hồi Văn bản Pháp lý cho Doanh nghiệp Nhỏ và Vừa (SME)
R2AI Stage 1 — Vietnamese Legal QA

1 Tổng quan Nguồn Dữ liệu

Hệ thống tự xây dựng corpus bằng cách cào trực tiếp từ Cơ sở Dữ liệu Quốc gia về Văn bản Pháp luật tại vbpl.vn. Đây là nguồn dữ liệu pháp lý chính thống của Nhà nước Việt Nam, miễn phí, không yêu cầu đăng nhập.

Thuộc tính	Chi tiết
Nguồn dữ liệu	https://vbpl.vn (Cơ sở DLQG về Văn bản Pháp luật)
Phương thức thu thập	Crawl tự động bằng Python (requests + BeautifulSoup), fallback sang Playwright khi trang render bằng JavaScript
Phạm vi	Chỉ cào các văn bản trực tiếp liên quan đến hoạt động SME (lao động, thuế, BHXH, doanh nghiệp, phá sản)
Đơn vị chunk	Mỗi Điều luật là một chunk độc lập
Thời điểm thu thập	Tháng 6/2026

2 Corpus Chính — corpus_luat_sme_merged_v3.jsonl

2.1 Quy trình Thu thập Chi tiết

- **Bước 1 — Tải trang (fetch):** Script thử tải bằng requests trước. Nếu trang trả về HTML không có nội dung điều khoản (vbpl.vn render nội dung bằng JavaScript theo yêu cầu), tự động chuyển sang Playwright với Chromium headless, chờ đến khi thẻ `p.prov-article` xuất hiện trong DOM.
- **Bước 2 — Tách nội dung:** Toàn văn nằm trong `div.preview-content`. Mỗi đoạn văn bản là thẻ `<p>` có class bắt đầu bằng `prov-*`, phân cấp như sau:

Class HTML	Cấp độ	Vai trò
<code>prov-part</code>	Phần	Phần I, II...
<code>prov-chapter</code>	Chương	Chương I, II...
<code>prov-section</code>	Mục	Mục 1, 2...
<code>prov-subsection</code>	Tiểu mục	Tiểu mục a, b...
<code>prov-article</code>	Điều	Ranh giới chunk
<code>prov-clause</code>	Khoản	Nội dung thuộc Điều
<code>prov-point</code>	Điểm	Nội dung thuộc Khoản
<code>prov-content</code>	Nội dung	Nội dung chi tiết

- **Bước 3 — Tạo chunk (chunking):** Mỗi prov-article (Điều) bắt đầu một chunk mới. Tất cả prov-clause, prov-point, prov-content tiếp theo được gom vào noi_dung của Điều đó cho đến khi gặp Điều kế tiếp. Tiêu đề Chương/Mục được lưu vào vi_tri để làm context.

2.2 Cấu trúc File

Định dạng: JSON array, mỗi phần tử là một Điều luật, mã hóa UTF-8. Schema gồm 4 trường:

Trường	Kiểu	Ý nghĩa
dieu	string	Nhãn Điều, ví dụ "Điều 8"— dùng để nhận diện và dedup
noi_dung	string	Toàn bộ nội dung Điều (tiêu đề + tất cả Khoản/Điểm) — đây là văn bản đưa vào embedder và reranker
metadata_truy_hoi	string	Chuỗi định danh dạng doc_id tên văn bản Điều X — dùng làm submission_article_str khi nộp
vi_tri	string	Chuỗi breadcrumb Phần > Chương > Mục, ví dụ "Chương I > QUY ĐỊNH CHUNG"— context bổ trợ, không đưa vào embedder

Cách metadata_truy_hoi sinh ra relevant_docs: Pipeline retrieval tách doc_id | tên (2 phần đầu) để tạo submission_doc_str:

```
# Trong hàm retrieve():
parts = art.split('|')
doc_key = f"{parts[0]}|{parts[1]}" # "38/2019/QH14|Luật Quản lý thuế..."
```

3 Tiền Xử lý Dữ liệu

Làm sạch văn bản (trong crawler):

- Xóa \xa0 (non-breaking space), \r, \t thừa.
- Gộp khoảng trắng liên tiếp.
- Gộp dòng trống liên tiếp ($\backslash n^+ \rightarrow \backslash n$).
- Loại bỏ các thẻ <p> không có class prov-* (tiêu đề trang, căn cứ pháp lý, metadata).
- Loại bỏ đoạn trùng lặp liên tiếp (do trang render sinh ra cặp <p id=...> và <p id=..._1> giống hệt nhau).
- **Không thực hiện word-segmentation:** noi_dung giữ nguyên văn bản tiếng Việt thô. Embedder BAAI/bge-m3 xử lý trực tiếp, không yêu cầu tokenize trước.