

MÔ HÌNH SỬ DỤNG

1. BAAI/bge-m3 — Dense Embedder

Thông tin mô hình:

- **Kiến trúc:** XLM-RoBERTa-Large, 560M parameters, đa ngôn ngữ (100+ ngôn ngữ)
- **Kích thước checkpoint:** ~2.27 GB (safetensors)
- **Precision sử dụng:** float16 (`model.half()`)
- **Độ dài đầu vào:** tối đa 8,192 tokens; hệ thống giới hạn 256 tokens/clause
- **Mục đích:** encode clause chunks và query thành dense vector, tính cosine similarity
- **Phiên bản checkpoint:** main (latest stable) — <https://huggingface.co/BAAI/bge-m3>

Hướng dẫn tải và sử dụng:

```
from sentence_transformers import SentenceTransformer

# Tải tự động (cần Internet):
embedder = SentenceTransformer("BAAI/bge-m3", device="cuda:0")
embedder.max_seq_length = 256
embedder.half() # fp16

# Tải thủ công về máy:
# huggingface-cli download BAAI/bge-m3 --local-dir ./models/bge-m3
```

2. BAAI/bge-reranker-v2-m3 — Cross-Encoder Reranker

Thông tin mô hình:

- **Kiến trúc:** XLM-RoBERTa-Large fine-tuned cho cross-encoder reranking
- **Kích thước checkpoint:** ~2.27 GB (safetensors)
- **Precision sử dụng:** float16
- **Độ dài đầu vào:** tối đa 512 tokens (query + passage)
- **Mục đích:** Sliding Window MaxP reranking — chia điều luật thành chunk 1,200 ký tự, score từng cặp (query, chunk), lấy max score
- **Phiên bản checkpoint:** main (latest stable) — <https://huggingface.co/BAAI/bge-reranker-v2-m3>

Hướng dẫn tải và sử dụng:

```
from sentence_transformers import CrossEncoder

# Tải tự động:
reranker = CrossEncoder("BAAI/bge-reranker-v2-m3", max_length=512, device="cuda:1")
reranker.model.half()

# Score pairs:
```

```
scores = reranker.predict([[query, passage1], [query, passage2]])

# Tải thủ công:
# huggingface-cli download BAAI/bge-reranker-v2-m3 --local-dir ./models/bge-reranker-v2-m3
```

3. Qwen/Qwen3-14B — LLM Answer Generation

Thông tin mô hình:

- **Kiến trúc:** Transformer decoder, 14B parameters, context window 32,768 tokens
- **Kích thước checkpoint:** ~28 GB (fp16) / ~9 GB (4-bit NF4 quantization)
- **Quantization:** 4-bit NF4 (bitsandbytes) + double quant, `compute_dtype=float16`
- **Ngôn ngữ:** đa ngôn ngữ, tiếng Việt chất lượng cao
- **Thinking mode:** hỗ trợ `/think` và `/no_think`; hệ thống dùng `THINKING="off"` để nhanh hơn
- **Mục đích:** sinh câu trả lời pháp lý tiếng Việt + trích dẫn điều luật theo format CITED / ANSWER / END
- **Phiên bản checkpoint:** main (latest stable, released 2025) — <https://huggingface.co/Qwen/Qwen3-14B>

Hướng dẫn tải và sử dụng (4-bit quantization):

```
from transformers import AutoModelForCausalLM, AutoTokenizer,
    BitsAndBytesConfig
import torch

model_id = "Qwen/Qwen3-14B"
bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_compute_dtype=torch.float16,
    bnb_4bit_use_double_quant=True,
    bnb_4bit_quant_type="nf4",
)

tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(
    model_id,
    quantization_config=bnb_config,
    device_map="auto",
)
model.eval()

# Tải thủ công (~9 GB với 4-bit):
# huggingface-cli download Qwen/Qwen3-14B --local-dir ./models/qwen3-14b
```

Tổng hợp đường link checkpoint

Mô hình	Phiên bản	Kích thước	Đường link
BAAI/bge-m3	main	~2.27 GB	https://huggingface.co/BAAI/bge-m3
BAAI/bge-reranker-v2-m3	main	~2.27 GB	https://huggingface.co/BAAI/bge-reranker-v2-m3
Qwen/Qwen3-14B	main	~9 GB (4-bit)	https://huggingface.co/Qwen/Qwen3-14B